

PREGLED I SAŽETAK

MAGISTARSKOG RADA

Upravljanje resursima i njihova alokacija u oblaku

Sažeti prikaz teme, metodologije, najvažnijih nalaza i statusa hipoteza

Autor magistarskog rada: Otuzbir Hadžo

Univerzitet u Zenici - Politehnički fakultet

Dokument za brzo razumijevanje rada i pripremu za razgovor s mentorom ili odbranu

Sažetak rada u jednoj stranici

Magistarski rad obrađuje upravljanje računarskim resursima u cloud okruženju, s posebnim naglaskom na njihovu alokaciju, raspoređivanje zadataka i dinamičko skaliranje. Polazna ideja je da oblak nije samo velika zbirka servera, nego dinamičan sistem u kojem se procesorska snaga, memorija, mreža i skladište moraju stalno prilagođavati promjenjivim zahtjevima korisnika. Ako su resursi dodijeljeni loše, posljedice mogu biti visoki troškovi, spor odziv, nedovoljna dostupnost i slaba iskorištenost infrastrukture.

Rad zato povezuje tri međuzavisna kriterija: performanse, funkcionalnost i cijenu. Povećanje kapaciteta može poboljšati performanse, ali istovremeno povećava trošak i potrošnju energije. Pretjerano smanjenje kapaciteta može donijeti kratkoročnu uštedu, ali ugroziti kvalitet usluge. Suština upravljanja resursima jeste pronaći ravnotežu u kojoj sistem ostvaruje traženi nivo usluge uz što racionalniju upotrebu infrastrukture.

Glavne cjeline rada

- teorijske osnove cloud computinga, modeli usluga i modeli implementacije;
- vrste cloud resursa i izazovi njihovog upravljanja;
- politike alokacije, scheduling i pravedno raspoređivanje zadataka;
- horizontalno i vertikalno skaliranje te automatizovano upravljanje;
- uticaj odluka o resursima na trošak, protok, odziv, energiju i efikasnost;
- razmatranje hipoteza, preporuke i plan mogućeg praktičnog eksperimenta.

Najvažniji zaključak je da ne postoji jedna univerzalno najbolja politika. Efikasno rješenje zavisi od karakteristika aplikacije, obrasca opterećenja, vremena pokretanja novih instanci, dostupnih metrika, modela naplate i zahtijevanog nivoa usluge. Rad zbog toga zagovara adaptivan i višekriterijski pristup, a ne slijepo povećavanje ili smanjivanje broja resursa.

Predmet, problem, ciljevi i metode

Predmet i problem istraživanja

Predmet rada jeste teorijska i djelimično ilustrativna analiza upravljanja i alokacije resursa u cloud okruženju. Posmatra se način na koji se resursi planiraju, raspoređuju, nadziru i prilagođavaju aplikacijama i korisničkim zahtjevima. Problem proizlazi iz činjenice da su cloud opterećenja promjenjiva, infrastruktura višekorisnička, a raspoloživi kapaciteti ograničeni i ekonomski mjerljivi.

Sistem mora istovremeno spriječiti dva nepovoljna stanja. Prvo je nedovoljna alokacija, pri kojoj nema dovoljno kapaciteta pa rastu vrijeme odziva, redovi čekanja i rizik od kršenja ugovorenog nivoa usluge. Drugo je prekomjerna alokacija, pri kojoj resursi ostaju neiskorišteni, ali se i dalje plaćaju i troše energiju. Istraživački problem je zato pronalazak politike koja se dovoljno brzo prilagođava opterećenju, a pritom ostaje stabilna, predvidiva i troškovno opravdana.

Ciljevi

- objasniti pojmove i mehanizme upravljanja cloud resursima;
- uporediti politike alokacije i scheduling pristupe;
- objasniti ulogu dinamičkog skaliranja;
- povezati upravljanje resursima s troškovima i efikasnošću;
- formulisati preporuke i razmotriti postavljene hipoteze.

Primijenjene metode

Korištene su deskriptivna, analitička, sintetička, induktivna i komparativna metoda. Rad se dominantno zasniva na analizi stručne i naučne literature. Uz to je uveden ilustrativni proračun koji poredi statičku i elastičnu alokaciju. Važno je naglasiti da ovaj proračun nije rezultat stvarno izvedenog eksperimenta, nego transparentan scenario zasnovan na jasno navedenim pretpostavkama.

Teorijske osnove cloud computinga

Cloud computing predstavlja model pružanja računarskih resursa i usluga putem mreže, na zahtjev i uz mogućnost brzog prilagođavanja kapaciteta. Korisnik ne mora posjedovati cjelokupnu fizičku infrastrukturu, nego koristi procesorsku snagu, memoriju, skladište, platforme ili aplikacije prema potrebi. Takav model omogućava elastičnost, skalabilnost i plaćanje prema korištenju, ali istovremeno povećava značaj pravilnog upravljanja zajedničkim resursima.

Modeli usluga

Kod modela IaaS korisniku se pružaju virtualizovani infrastrukturni resursi, dok korisnik zadržava veću odgovornost za operativni sistem, aplikacije i podatke. PaaS pruža razvojnu i izvršnu platformu, pa se korisnik više usmjerava na aplikaciju, a manje na administraciju nižih slojeva. SaaS korisniku daje gotovu aplikaciju, dok pružalac usluge upravlja gotovo cijelim tehnološkim slojem. Razlika među modelima važna je zato što određuje ko donosi odluke o kapacitetu, skaliranju i održavanju.

Modeli implementacije

Javni oblak nudi visoku skalabilnost i niže početne troškove, ali korisnik ima manje direktne kontrole. Privatni oblak daje veći stepen kontrole i prilagođavanja, uz veće troškove uspostavljanja i održavanja. Hibridni oblak kombinuje oba pristupa, dok community cloud dijeli više organizacija sa sličnim zahtjevima. Izbor modela utiče na dostupne politike upravljanja, sigurnost, troškove i mogućnost premještanja opterećenja.

Uloga virtualizacije

Virtualizacija omogućava da se fizički resursi podijele na više virtualnih mašina ili kontejnera. Time se povećava iskorištenost hardvera i olakšavaju migracija, izolacija i dinamička dodjela kapaciteta. Ipak, virtualizacija sama po sebi ne garantuje efikasnost: ako se resursi planiraju loše, moguće su interferencije, zagušenja i nepotrebni troškovi. Zato virtualizacija predstavlja tehničku osnovu, dok politike upravljanja određuju kvalitet njenog korištenja.

Upravljanje resursima u oblaku

Upravljanje resursima obuhvata planiranje, dodjelu, nadzor i ponovno raspoređivanje procesorskih, memorijskih, mrežnih i skladišnih kapaciteta. Procesorski resursi određuju brzinu obrade; memorija utiče na mogućnost istovremenog izvršavanja procesa; mreža određuje propusnost i latenciju; skladište utiče na kapacitet, IOPS i vrijeme pristupa podacima. Usko grlo u samo jednoj kategoriji može ograničiti cijeli sistem, pa se resursi ne smiju posmatrati izolovano.

Zašto je upravljanje teško

Cloud sistem radi u uslovima promjenjivog i djelimično nepredvidivog opterećenja. Broj korisnika i intenzitet zahtjeva mogu se mijenjati iz minute u minutu. Istovremeno se izvršavaju transakcijske, analitičke, interaktivne i batch aplikacije sa različitim prioritetima. Sistem nema uvijek potpuno i trenutno znanje o globalnom stanju, pa odluke donosi na osnovu mjerenja koja mogu kasniti ili biti nepotpuna.

Dodatni izazovi su heterogenost hardvera, višekorisničko dijeljenje, kvarovi, potreba za izolacijom, pravednost raspodjele i skalabilnost samih upravljačkih mehanizama. Centralizovani pristup daje jedinstvenu sliku, ali može postati usko grlo. Distribuirani pristup bolje skalira, ali zahtijeva koordinaciju i može donositi međusobno konfliktne odluke.

Performanse, funkcionalnost, cijena i energija

Rad naglašava da odluka o resursima gotovo uvijek predstavlja kompromis. Veći kapacitet može ubrzati izvršavanje i povećati dostupnost, ali podiže trošak. Konsolidacija opterećenja i gašenje nedovoljno iskorištenih instanci mogu smanjiti potrošnju energije, ali preagresivno smanjenje može ugroziti odziv. Kvalitetna politika zato koristi više pokazatelja: CPU i memoriju, red čekanja, stopu zahtjeva, percentil vremena odziva, greške, trošak i poštivanje SLA-a.

Alokacija resursa i scheduling

Alokacija određuje koliko resursa dobija određena aplikacija, korisnik ili zadatak, dok scheduling određuje redoslijed i mjesto izvršavanja. Ova dva procesa su povezana: zadatak može imati visok prioritet, ali se ne može izvršiti bez dovoljnog procesorskog, memorijskog ili mrežnog kapaciteta. Cilj nije samo održati sistem aktivnim, nego postići dobar protok, prihvatljivo vrijeme obrta i pravednu raspodjelu.

Najvažniji scheduling pristupi

Preemptivno planiranje omogućava prekid manje važnog zadatka kako bi se oslobodili resursi za hitniji posao. Prednost je brži odziv prioriternih zadataka, a nedostatak trošak prekida i nastavka. Nepreemptivno planiranje je jednostavnije i predvidivije, ali dugi zadatak može zadržati resurse i povećati čekanje drugih korisnika.

Prioritetno planiranje štiti poslovno važne klase, ali može dovesti do izgladnjivanja zadataka nižeg prioriteta. Fair queuing nastoji ravnomjernije dijeliti kapacitet među korisnicima ili tokovima. Deadline scheduling daje prednost zadacima s rokom, dok data-aware pristupi smanjuju mrežni prenos tako što zadatak izvršavaju bliže podacima. Nijedan pristup nije optimalan za sve vrste opterećenja.

Kako se bira politika

Izbor politike zavisi od cilja sistema. Interaktivne aplikacije naglašavaju odziv i stabilnost, batch poslovi protok, analitički zadaci lokalnost podataka, a kritične usluge rokove i dostupnost. Dobra politika uključuje zaštitne granice, praćenje učinka i period stabilizacije. Potrebno je spriječiti da upravljački sistem prečesto premješta zadatke ili mijenja kapacitet, jer takvo oscilovanje može potrošiti više resursa nego što ih štedi.

Dinamičko skaliranje i optimizacija

Dinamičko skaliranje je mehanizam kojim se raspoloživi kapacitet prilagođava stvarnom ili očekivanom opterećenju. Horizontalno skaliranje povećava ili smanjuje broj instanci, virtualnih mašina ili podova. Vertikalno skaliranje mijenja količinu procesora, memorije ili drugih resursa dodijeljenih postojećoj instanci. Horizontalni pristup je pogodan za distribuirane aplikacije, dok vertikalni može biti jednostavniji za sisteme koji se teže dijele na više replika.

Reaktivno, proaktivno i hibridno skaliranje

Reaktivna politika reaguje nakon što metrika pređe definisani prag. Jednostavna je i robusna, ali može kasniti jer je potrebno vrijeme da se nova instanca pokrene i postane spremna. Proaktivna politika koristi prethodne obrasce ili prognozu kako bi kapacitet obezbijedila prije porasta potražnje. Ona može dati bolji odziv, ali zavisi od tačnosti predviđanja. Hibridni pristup povezuje prognozu s brzom reaktivnom korekcijom.

Zašto samo CPU nije dovoljan

CPU iskorištenost je važna, ali ne opisuje uvijek korisničko iskustvo. Aplikacija može imati nizak CPU, a ipak spor odziv zbog baze podataka, mreže, zaključavanja ili vanjskog servisa. Zbog toga politika treba povezati infrastrukturne metrike s aplikacijskim pokazateljima, kao što su red čekanja, stopa zahtjeva, broj grešaka i 95. percentil vremena odziva.

Ciljevi optimizacije

Rad posmatra maksimiziranje protoka, minimiziranje vremena obrta, smanjenje troškova i potrošnje energije. Ovi ciljevi mogu biti u konfliktu: visoka iskorištenost smanjuje prazni kapacitet, ali ostavlja manju rezervu za vršna opterećenja. Zato automatizacija mora imati minimalne i maksimalne granice, histerezu i dovoljno vremena da prethodna odluka pokaže učinak prije nove promjene.

Najvažniji analitički nalazi

U završnoj analizi rad povezuje teorijske tvrdnje s troškovima i efikasnošću korištenja IT resursa. Najvažniji nalaz jeste da elastična alokacija može smanjiti vrijeme tokom kojeg je kapacitet aktiviran, pod uslovom da sistem dovoljno tačno prati potražnju i da se resursi mogu pravovremeno uključivati i isključivati.

Ilustrativni proračun

U prikazanom dnevnom scenariju statička politika stalno drži deset instanci, što daje 240 instanca-sati aktiviranog kapaciteta. Pretpostavljeni koristan rad iznosi 153 instanca-sata. Elastična politika prati promjene potražnje i aktivira ukupno 174 instanca-sata, dok je zahtijevani koristan rad isti. Odnos korisnog i aktiviranog kapaciteta zato raste sa 63,8% na 87,9%, a aktivirani kapacitet se smanjuje za 27,5%.

Ovaj rezultat pokazuje pravac mogućeg efekta, ali nije tržišna cijena niti rezultat mjerenja u stvarnom cloudu. Stvarna ušteda zavisi od obračunskog intervala, cijena instanci, vremena pokretanja, mrežnog prenosa, licenci, pohrane, migracija i troška administracije. Elastična politika može koristiti manje instanca-sati, a ipak biti skuplja ako izaziva prekide, greške ili česte migracije.

Širi zaključci

- kvalitet se ne mjeri samo iskorištenošću, nego i odzivom, dostupnošću i greškama;
- najmanji broj aktivnih resursa nije uvijek ekonomski optimalan;
- politika mora uzeti u obzir vrijeme potrebno za reakciju sistema;
- stabilnost i predvidivost upravljanja jednako su važne kao brzina;
- odluke treba redovno provjeravati stvarnim mjerenjima i ponovljivim testovima.

Hipoteze: šta je zapravo potvrđeno?

Rad ima dvije jasno postavljene hipoteze. One nisu dokazane u strogom eksperimentalnom smislu, nego su razmotrene na osnovu literature, komparativne analize i ilustrativnog proračuna. Zbog toga ih rad ocjenjuje kao uslovno prihvaćene.

Hipoteza	Osnova za ocjenu	Zaključak
H1: Kvalitetnim upravljanjem resursima i njihovom alokacijom mogu se minimizirati troškovi pružanja usluge u oblaku.	Literatura o elastičnosti i troškovno svjesnom skaliranju te ilustrativno smanjenje aktiviranog kapaciteta za 27,5%.	Uslovno prihvaćena. Trošak se može smanjiti u odnosu na lošije prilagođenu politiku, ali se ne garantuje apsolutno najmanji račun.
H2: Kvalitetno upravljanje resursima i njihova alokacija mogu unaprijediti efikasnost korištenja IT resursa.	Veći odnos korisnog i aktiviranog kapaciteta u ilustrativnom scenariju te nalazi o schedulingu, lokalnosti i skaliranju.	Uslovno prihvaćena. Efikasnost se mora mjeriti zajedno s odzivom, dostupnošću, greškama i rezervom kapaciteta.

Odgovor na pitanje: da li rad dokazuje hipoteze?

Ne u potpunom naučno-eksperimentalnom smislu. Rad pruža teorijsku argumentaciju i ilustraciju koja podržava obje hipoteze, ali nema mjerenja iz stvarno izvedenog eksperimenta, statističkog testa niti provedene ankete. Najpreciznije je reći da su hipoteze argumentovano i uslovno potvrđene u okviru teorijsko-komparativnog rada. Za jaču potvrdu bilo bi potrebno izvesti planirani eksperiment i analizirati stvarne rezultate.

Doprinos, ograničenja i završna ocjena

Glavni doprinos

Rad sistematizuje ključne pojmove upravljanja cloud resursima i povezuje tehničke odluke sa ekonomskim posljedicama. Posebna vrijednost je u objedinjavanju alokacije, schedulinga, skaliranja, performansi, troška i energije u jednu cjelinu. Komparativne tabele, dijagrami i ilustrativni proračun olakšavaju razumijevanje kompromisa među različitim politikama.

Najvažnija ograničenja

Rad je dominantno teorijski. Veliki dio zaključaka izveden je iz literature i pojednostavljenog scenarija. Nisu provedeni testovi na stvarnoj cloud platformi, nisu prikupljene sirove metrike i anketa iz dodatka nije distribuirana. Zbog toga zaključci opisuju vjerovatne odnose i preporuke, ali ne mjere tačan efekat određene konfiguracije u konkretnom proizvodnom sistemu.

Planirani praktični nastavak

Dodatak rada predlaže eksperiment na Kubernetes klasteru. Statički broj replika mogao bi se porediti s reaktivnim HPA skaliranjem i politikom zasnovanom na aplikacijskoj metrici ili rasporedu. Mjerili bi se prosječno i 95. percentil vremena odziva, protok, greške, broj replika, pod-sati ili instanca-sati, potrošnja procesora i memorije te kašnjenje od prelaska praga do spremnosti nove replike. Svaki scenario trebalo bi ponoviti najmanje pet puta.

Šta treba zapamtiti

- Tema rada je optimizacija cloud sistema pravilnim upravljanjem i alokacijom resursa.
- Najvažniji kompromis je odnos performansi, troška, dostupnosti i energije.
- Ne postoji jedna najbolja politika za sva opterećenja i sve aplikacije.
- Obje hipoteze postoje i u radu su prihvaćene uslovno, a ne definitivno dokazane.
- Praktični eksperiment bi predstavljao najjače moguće proširenje i potvrdu zaključaka.

Završna ocjena: rad daje preglednu i argumentovanu teorijsku osnovu za razumijevanje upravljanja cloud resursima. Njegova centralna poruka jeste da automatizacija ima vrijednost samo kada je zasnovana na relevantnim metrikama, pravilno postavljenim granicama i kontinuiranoj provjeri stvarnog učinka.